

# Instituto Tecnológico y de Estudios Superiores de Monterrey



ESTANCIA DE INVESTIGACIÓN (GPO 572)

SEMESTRE JULIO - DICIEMBRE 2025

---

## Análisis de series de tiempo financieras implementando métodos de TDA

---

### **Autor**

Pablo Pérez Sanadoval

A01710355

### **Docente**

Jonathan Montalvo Urquizo

25 de noviembre de 2025  
Monterrey, Nuevo León

## Resumen

Este trabajo investiga el uso de características de *Topological Data Analysis* (TDA) como variables exógenas para el pronóstico de series de tiempo financieras mediante modelos de aprendizaje profundo. Basándonos en trabajos recientes que combinan homología persistente con arquitecturas neuronales, construimos un panel de datos para diez acciones de gran capitalización y entrenamos modelos N-BEATSX **con y sin** características derivadas de TDA, calculadas a partir de la topología de ventanas deslizantes de log-return.

El estudio se desarrolla en dos etapas. Primero, un experimento piloto con una arquitectura N-BEATS implementada manualmente y un preprocesamiento agresivo de la señal produjo pronósticos casi constantes y un desempeño pobre, en buena medida por la inexperiencia al diseñar la arquitectura y por una eliminación excesiva de ruido que suprimió información relevante. Estos resultados motivaron un rediseño del flujo de trabajo en torno a la implementación pública de N-BEATSX en la librería `neuralforecast`, utilizando un objetivo más simple (log-returns escalados con MinMax) y agregando descriptores de TDA —entropía, amplitud y número de puntos en diagramas de persistencia de  $H_1$ — como variables exógenas históricas.

Los modelos se evalúan mediante *backtesting* con origen rodante y un horizonte de 5 días hábiles, utilizando MAPE, MAE, RMSE y MASE como métricas. El objetivo principal es cuantificar la contribución marginal de las características de TDA más allá de la información exógena estándar en un escenario realista de pronóstico de acciones.

**Palabras clave:** Topological Data Analysis, N-BEATSX, series de tiempo financieras, pronóstico, aprendizaje profundo.

## 1. Introducción

El pronóstico de series de tiempo financieras ha sido un problema central en economía y finanzas cuantitativas desde hace varias décadas, con métodos que van desde modelos lineales clásicos hasta técnicas modernas de aprendizaje automático. Sin embargo, sigue siendo una tarea desafiante debido al alto nivel de ruido, la no estacionariedad, la presencia de cambios de régimen y las estructuras de dependencia complejas tanto en el tiempo como entre distintos activos.

Recientemente, *Topological Data Analysis* (TDA) ha emergido como un marco prometedor para extraer descriptores globales de la forma de los datos a partir de series de tiempo, combinando embeddings de retrasos, homología persistente y resumen de diagramas de persistencia. En particular, [1] proponen mejorar el pronóstico de series financieras mediante la incorporación de características basadas en TDA a modelos clásicos, mostrando que los descriptores topológicos pueden aportar información complementaria sobre regímenes de mercado y estructura temporal.

En este trabajo retomamos esa idea y estudiamos el uso de características de TDA como variables exógenas para N-BEATSX, una arquitectura moderna de aprendizaje profundo para el pronóstico de series univariadas y paneles. La principal diferencia entre este trabajo y el artículo anteriormente mencionado, conciste en las bases de datos usadas en el experimento. Mientras que en [1] se

centra en criptomonedas, en este experimento nos centramos en la experimentación con datos provenientes de la bolsa de valores estadounidense.

Este estudio se desarrolló en dos etapas:

1. Un estudio piloto, en el que una red tipo N-BEATS implementada manualmente, junto con un preprocesamiento intenso de los retornos (winsorización, descomposición wavelet y normalización agresiva), produjo resultados pobres y pronósticos casi constantes. Este enfoque no solo resultó difícil de implementar y calibrar, sino que además el fuerte preprocesamiento terminó alterando en exceso la estructura original de las series, alejando el experimento del objetivo principal de trabajar con datos de mercado lo más cercanos posible a las observaciones reales.
2. Un diseño experimental rediseñado y más robusto, utilizando la implementación pública de N-BEATSX en `neuralforecast`, una definición más simple del objetivo, y características de TDA integradas como entradas exógenas históricas.

## 2. Antecedentes y trabajos relacionados

### 2.1. Pronóstico de series de tiempo en mercados financieros

Los enfoques clásicos para el pronóstico de series financieras incluyen modelos lineales como ARIMA y modelos de espacio de estados, así como modelos de volatilidad tipo GARCH y sus variantes. Más recientemente, modelos de aprendizaje automático y aprendizaje profundo, como perceptrones multicapa, redes neuronales recurrentes, redes convolucionales temporales y Transformers, se han utilizado para modelar el comportamiento no lineal y no estacionario de los retornos de activos. A pesar de su flexibilidad, estos modelos suelen operar de manera coordinada y local, y pueden no explotar plenamente patrones geométricos globales en la serie.

### 2.2. Topological Data Analysis

*Topological Data Analysis* proporciona herramientas para estudiar la forma de los datos de manera invariante a escala. Un flujo típico comienza con un embedding de retrasos de Takens de la serie de tiempo en un espacio de mayor dimensión, luego construye un complejo simplicial (por ejemplo, Vietoris–Rips) sobre la nube de puntos resultante y calcula la homología persistente. El resultado es un diagrama de persistencia, que registra los tiempos de nacimiento y muerte de características topológicas como componentes conexas, bucles y cavidades en función de un parámetro de escala. Los diagramas de persistencia pueden resumirse mediante estadísticas como persistencia total, entropía, amplitud o número de puntos, produciendo vectores de características de longitud fija aptos para modelos de aprendizaje.

### 2.3. TDA en finanzas

En finanzas, TDA se ha utilizado para caracterizar la estructura de redes de correlación, detectar cambios de régimen en mercados y construir características para la gestión de riesgo y pronóstico. En particular, de Jesus et al. [1] proponen mejorar el pronóstico de series de tiempo financieras agregando descriptores de TDA calculados a partir de diagramas de persistencia de series de retornos embebidas. Sus resultados sugieren que las características topológicas pueden capturar aspectos de la complejidad del mercado que no son fácilmente codificables mediante indicadores técnicos estándar.

### 2.4. Modelos de aprendizaje profundo para pronóstico (N-BEATS, N-BEATSX)

N-BEATS es una arquitectura de red neuronal profunda para el pronóstico de series univariadas basada en pilas de bloques totalmente conectados con conexiones residuales hacia atrás y hacia adelante. N-BEATSX extiende este marco para incorporar variables exógenas y datos tipo panel, permitiendo entrenar un único modelo sobre múltiples series mientras se condiciona en covariables. La librería `neuralforecast` de Nixtla proporciona una implementación pública de N-BEATSX adaptada a problemas de pronóstico a gran escala, lo que la convierte en una base adecuada para nuestro estudio.

## 3. Datos

### 3.1. Descripción de los datos de mercado

El análisis empírico se basa en diez acciones de alta relevancia global, seleccionadas por su tamaño, liquidez e influencia en los mercados internacionales. Los *tickers* considerados son:

AAPL, MSFT, GOOGL, AMZN, NVDA, META, TSM, LLY, BRK-B, NVO.

Se recolectan datos diarios para estos activos desde el 1 de enero de 2019 hasta el 31 de octubre de 2025, usando frecuencia de días hábiles. Para cada activo se obtienen precios de cierre ajustados y se construye un único panel en formato largo con columnas

$$(\text{unique\_id}, \text{ds}, \mathbf{Y}) \cup \{\text{características exógenas}\},$$

donde `unique_id` identifica al activo, `ds` es la fecha y `Y` denota la serie objetivo.

Debido a la construcción de las características de TDA sobre ventanas deslizantes de longitud 21 días, las primeras 21 observaciones de cada serie producen valores `NaN` en las columnas de TDA. Como consecuencia, la fecha de inicio efectiva del panel utilizado para el modelado es el 31 de enero de 2019.

### 3.2. Preprocesamiento

La variable objetivo en todos los experimentos es una versión transformada de los log-return diarios. Para cada activo se procede de la siguiente manera:

1. Se calcula el log-retorno a partir de los precios de cierre ajustados:

$$r_t = \log \left( \frac{P_t}{P_{t-1}} \right).$$

2. Se aplica un escalado MinMax a los log-return, obteniendo la serie escalada `logret_scaled`, que se utiliza como objetivo y en los modelos N-BEATSX finales.

En el estudio piloto (véase Sección 4) se exploraron pasos de preprocesamiento adicionales, incluyendo filtrado por wavelets y normalizaciones más agresivas. No obstante, estas transformaciones llevaron a modelos con bajo desempeño y predicciones casi constantes, lo que sugiere que un denoising excesivo eliminó información relevante de la serie. En el diseño experimental final, por tanto, se restringe la transformación del objetivo a escalado MinMax, que siguen siendo simples e interpretables.

La misma definición de `logret_scaled` se utiliza tanto para el modelo base (sin TDA) como para el modelo con TDA. Todas las variables exógenas no topológicas, cuando están presentes, también se mantienen idénticas en ambas configuraciones.

### 3.3. Construcción de las columnas exógenas

Además de la propia serie objetivo, el modelo N-BEATSX se entrenó utilizando variables exógenas de calendario y de estado de mercado. En particular, se incorporaron como *future exogenous* (`futr_exog`) las columnas [`'dow'`, `'dom'`, `'woy'`, `'month'`, `'qtr'`, `'eom'`, `'eoq'`, `'eoy'`], que codifican información temporal determinista (día de la semana, día del mes, semana del año, mes, trimestre y dummies de fin de mes, fin de trimestre y fin de año) conocida para todo el horizonte de pronóstico. Como *historical exogenous* (`hist_exog`) se utilizaron las variables [`'vix'`, `'rv_5'`, `'rv_10'`, `'rv_21'`], que resumen el estado reciente del mercado mediante el índice de volatilidad implícita y medidas de volatilidad realizada a 5, 10 y 21 días. No se incluyeron variables exógenas estáticas (`stat_exog = None`) en este experimento.

### 3.4. Construcción de las características de TDA

Para construir características exógenas basadas en TDA seguimos un flujo inspirado en de Jesus et al. [1] y adaptado a nuestro contexto:

1. **Embedding de retrasos.** Para cada activo, se considera la serie escalada `logret_scaled` y se construye un embedding de Takens de dimensión  $k = 4$  con retraso  $s = 4$ . Esto genera, para cada instante  $t$ , un punto en  $\mathbb{R}^4$  que codifica la trayectoria reciente de la serie.

2. **Homología persistente en  $H_1$ .** Sobre la nube de puntos resultante se construye un complejo de Vietoris–Rips y se calcula la homología persistente en dimensión  $H_1$ , capturando estructuras tipo bucle en la trayectoria embebida. Esto produce diagramas de persistencia cuyos puntos corresponden a escalas de nacimiento y muerte de características topológicas unidimensionales.
3. **Resumen por ventanas deslizantes.** Usando una ventana deslizante de longitud  $w = 21$  días hábiles sobre la serie embebida, se calculan para cada fecha descriptores agregados del diagrama de persistencia en  $H_1$ :

$$\text{tda\_amplitude\_h1\_w21}, \quad \text{tda\_n\_points\_h1\_w21}.$$

Aquí, la amplitud mide la magnitud global de las características topológicas y el número de puntos refleja la complejidad topológica local en términos de cuántos ciclos persistentes aparecen en el diagrama.

Estas dos características de TDA se añaden al panel de datos como variables exógenas. En la implementación de N-BEATSX se tratan exclusivamente como covariables exógenas históricas (`hist_exog`), asegurando que no se filtre al modelo información proveniente del futuro dentro del horizonte de pronóstico.

## 4. Metodología

### 4.1. Formulación del problema

Sea  $y_t$  el log-retorno escalado `logret_scaled` de un activo dado en el tiempo  $t$ . Para cada activo indexado por  $i$  y tiempo  $t$ , escribimos  $y_{i,t}$  para el objetivo y  $X_{i,t}$  para el vector de variables exógenas, incluyendo tanto covariables estándar como, en la especificación con TDA, descriptores topológicos.

Consideramos un problema de pronóstico a  $h$  pasos con horizonte  $H = 5$  días hábiles. Dada la historia  $\{y_{i,t}, X_{i,t}\}_{t \leq T}$  para cada activo  $i$ , el objetivo es aprender una función  $f_\theta$  tal que

$$\hat{y}_{i,T+h} = f_\theta(\{y_{i,t}\}_{t \leq T}, \{X_{i,t}\}_{t \leq T}),$$

para  $h = 1, \dots, H$ , donde  $\theta$  denota los parámetros del modelo. Adoptamos un enfoque de panel donde un único modelo N-BEATSX se entrena de manera conjunta sobre los diez activos, compartiendo parámetros entre series mientras se condiciona en covariables específicas de cada activo.

## 4.2. Modelos base (sin TDA)

El modelo base principal es un N-BEATSX entrenado sobre el panel descrito en la Sección 3, usando la siguiente configuración:

- Frecuencia: `FREQ = "B"` (días hábiles).
- Horizonte de pronóstico:  $H = 5$  días hábiles.
- Número de ventanas de *backtesting*: `N_WINDOWS = 4`.
- Semilla aleatoria: `SEED = 42`.
- Número máximo de pasos de entrenamiento: `MAX_STEPS = 1500`.
- Tamaño de lote: `BATCH_SIZE = 128`.
- Tasa de aprendizaje: `LEARNING_RATE = 1 \times 10^{-3}`.
- Tipo de escalador interno: `SCALER_TYPE = robust`.

Los diez activos se incluyen en un único modelo mediante el identificador `unique_id`. El modelo base utiliza `logret_scaled` como objetivo y puede incluir variables exógenas estándar (por ejemplo, efectos de calendario o indicadores de mercado), pero *no* incluye ninguna característica derivada de TDA.

## 4.3. Modelos con variables exógenas basadas en TDA

El modelo con TDA comparte la misma arquitectura, hiperparámetros, estructura de panel y definición del objetivo que el modelo base. La única diferencia es la inclusión de los dos descriptores de TDA

`tda_amplitude_h1_w21, tda_n_points_h1_w21`

como variables exógenas históricas (`hist_exog`) en el modelo N-BEATSX.

Por construcción, ambos modelos usan divisiones de datos idénticas, el mismo esquema de escalado y las mismas variables exógenas no relacionadas con TDA. Este diseño asegura que cualquier diferencia de desempeño pueda atribuirse a la contribución marginal de las características de TDA, y no a cambios colaterales en el preprocesamiento o la arquitectura.

## 4.4. Estudio piloto y lecciones aprendidas

Antes de adoptar la implementación de N-BEATSX en `neuralforecast`, se realizó un experimento piloto utilizando una red neuronal tipo N-BEATS implementada manualmente. En esta configuración preliminar:

- Se diseñó una arquitectura totalmente conectada con bloques residuales inspirados en N-BEATS y se entrenó directamente sobre la serie de log-return.

- Se consideraron horizontes de pronóstico de  $H = 1$  y  $H = 5$  días hábiles.
- El flujo de preprocesamiento buscó seguir de cerca las estrategias de denoising de de Jesus et al. [1], incluyendo filtrado por wavelets y normalizaciones fuertes, además de la winsorización.

A pesar de ello, el modelo piloto mostró un comportamiento insatisfactorio:

- Las métricas MAE, MAPE y RMSE fueron consistentemente peores que las de un baseline ingenuo, como un modelo de caminata aleatoria o persistencia.
- La red tendía a producir pronósticos concentrados en un rango estrecho (aproximadamente entre 0 y 0.3 en el espacio escalado), sin capturar movimientos más pronunciados en la serie.
- Los tiempos de entrenamiento eran relativamente altos, dificultando la exploración sistemática del espacio de hiperparámetros.

La conclusión principal de este estudio piloto fue que la combinación de un denoising agresivo y una implementación propia de N-BEATS eliminó demasiada variabilidad que contenía señal predictiva en los retornos de acciones. Es decir, al intentar “limpiar” en exceso los datos, el modelo perdió acceso a patrones que, aunque ruidosos, son precisamente los que hacen que el pronóstico sea difícil pero potencialmente informativo.

Estas observaciones motivaron un cambio metodológico hacia:

1. Utilizar una definición más simple y transparente del objetivo, restringida a log-return winsorizados y escalados con MinMax, sin filtrado adicional por wavelets en el experimento final, y
2. Adoptar una implementación consolidada y probada públicamente de N-BEATSX, de modo que el foco del estudio se centre en el papel de las características de TDA y no en estabilizar una arquitectura propia.

En este sentido, el experimento piloto se trata como un *pilot study* que informa el diseño de la metodología final, más que como una configuración a comparar cuantitativamente en la sección de resultados.

#### 4.5. Diseño experimental

El diseño experimental final se basa en un único modelo de panel para los diez activos y un esquema de evaluación con origen rodante:

- El conjunto de datos se divide en un periodo de entrenamiento y un periodo de prueba, respetando el orden temporal. Sólo se utiliza información pasada para pronosticar valores futuros.



- Dentro del periodo de prueba se realiza *backtesting* con  $N\_WINDOWS = 4$  ventanas rodantes. Para cada origen, el modelo produce pronósticos para los siguientes  $H = 5$  días hábiles.
- Tanto el modelo base como el modelo con TDA se entrenan y evalúan bajo las mismas divisiones de datos y ventanas de *backtesting*.

La comparación experimental se realiza entonces entre:

**Base:** N-BEATSX sin características de TDA, entrenado sobre el panel con `logret_scaled` como objetivo.

**Modelo TDA:** N-BEATSX con la misma configuración, más los dos descriptores de TDA como covariables exógenas históricas.

#### 4.6. Métricas de evaluación y pruebas estadísticas

Para cada ventana de *backtesting* y cada horizonte  $h \in \{1, \dots, 5\}$  se calculan métricas estándar de error de pronóstico, tanto agregadas a través de activos como, cuando es relevante, por activo individual:

- Error porcentual absoluto medio (MAPE),
- Error absoluto medio (MAE),
- Raíz del error cuadrático medio (RMSE),
- Error absoluto medio escalado (MASE).

Estas métricas ofrecen perspectivas complementarias sobre el desempeño: MAE y RMSE se centran en desviaciones absolutas y cuadráticas, MAPE normaliza los errores por la magnitud del objetivo y MASE permite la comparación contra un benchmark ingenuo. En la etapa actual del proyecto nos centramos principalmente en comparaciones descriptivas entre el modelo base y el modelo con TDA.

### 5. Resultados

El experimento evalúa el impacto de incorporar características de Topological Data Analysis (TDA) en el pronóstico de log-retornos diarios (re-escalados con MinMax) de diez acciones que cotizan en la bolsa de valores de Estados Unidos, en el periodo 2019–2025. Se compara una versión de N-BEATSX con variables exógenas topológicas (amplitud y número de puntos persistentes en  $H_1$  para una ventana de 21 días), frente a un modelo base sin TDA, utilizando un esquema de backtesting tipo validación cruzada con horizonte de cinco días.

A nivel global del panel, las métricas de error obtenidas a partir de las curvas de validación cruzada muestran una mejora consistente al incorporar TDA. El *MAPE* promedio pasa de 144,73 sin TDA a 138,16 con TDA, lo que representa una reducción relativa cercana al 4,5, %. De forma similar, el *MAE* se reduce de

0,764 a 0,754 (mejora de alrededor de 1,3 %) y el *MASE* de 0,766 a 0,752 (mejora de aproximadamente 1,8 %). En contraste, el *RMSE* se mantiene prácticamente inalterado, con valores muy similares en ambos modelos (0,988 sin TDA frente a 0,988 con TDA), lo que indica que la mejora se concentra principalmente en errores absolutos y relativos, más que en la reducción de errores cuadráticos grandes.

El análisis punto a punto de los errores absolutos confirma este patrón. Definiendo  $\Delta|e| = |e_{\text{TDA}}| - |e_{\text{sin TDA}}|$ , el resumen global sobre las  $N = 50$  predicciones del horizonte de cinco días muestra que en un 64 % de los casos el modelo con TDA presenta un error absoluto menor ( $\Delta|e| < 0$ ), mientras que en el 36 % restante el modelo base sin TDA es mejor. La media de  $\Delta|e|$  es de  $-0,1509$  y la mediana de  $-0,1165$ , ambas negativas, lo que indica una ganancia típica moderada a favor de la versión con TDA en la escala normalizada de los retornos.

Esta mejora no es completamente homogénea entre activos, pero sí predominante. El resumen por activo muestra que, para siete de las diez acciones (AAPL, BRK-B, GOOGL, LLY, META, NVDA y TSM), el modelo con TDA obtiene un error absoluto menor en más de la mitad de los puntos del horizonte de pronóstico. En particular, TSM presenta  $\Delta|e| < 0$  en el 100 % de las observaciones, y activos como AAPL y NVDA también exhiben reducciones medias de error absoluto relativamente pronunciadas. En cambio, en AMZN, MSFT y NVO la proporción de puntos donde el modelo sin TDA es mejor supera el 50 %, y las medias de  $\Delta|e|$  son positivas, reflejando que la incorporación de TDA puede deteriorar ligeramente el desempeño en ciertos activos individuales.

Finalmente, el histograma de la distribución de  $\Delta|e|$  muestra que las diferencias de error absoluto se concentran en un rango acotado aproximadamente entre  $-1$  y  $1$ , con la mayor parte de la masa alrededor de valores negativos moderados, en línea con la media ( $-0,1509$ ) y mediana ( $-0,1165$ ) globales. Esto sugiere que el modelo con TDA no produce cambios drásticos en el error para la mayoría de las observaciones, pero sí introduce una mejora sistemática y consistente en el error absoluto típico sobre el conjunto de activos y horizontes considerados.

## 6. Conclusiones

Los resultados de este estudio muestran que la incorporación de características topológicas, en particular la amplitud de los diagramas de persistencia y el número de puntos persistentes, puede aportar información útil para el pronóstico de series de tiempo financieras. En una proporción relevante de los casos analizados, los modelos que incorporan estas variables superan, en términos de error absoluto, a sus contrapartes sin información TDA. Esto sugiere que la estructura topológica implícita en los retornos financieros contiene señales que no son capturadas de forma directa por transformaciones tradicionales, y que dichas señales pueden aprovecharse como insumos adicionales en modelos de aprendizaje profundo.

Sin embargo, la elección de N-BEATSX como modelo base no resultó ser la más adecuada para el objetivo final de este trabajo, que está motivado por aplicaciones de trading. Desde una perspectiva práctica, el interés principal no es tanto reducir el error en la predicción puntual del nivel de la serie, sino obtener una ventaja explotable en términos de decisiones de compra o venta. En ese contexto, un modelo específicamente entrenado para resolver una tarea binaria (por ejemplo, predecir si el precio subirá o bajará en un horizonte dado) es conceptualmente más alineado con el problema que un modelo de regresión multihorizonte como N-BEATSX, que no está diseñado de forma nativa para optimizar separaciones binarias.

Los hallazgos de este experimento sugieren, por tanto, que el verdadero potencial de las características TDA en finanzas podría manifestarse con mayor claridad en modelos cuyo objetivo sea directamente la clasificación direccional o la toma de decisiones, más que en la predicción exacta de los niveles futuros. En particular, resulta prometedor explorar arquitecturas de clasificación (por ejemplo, redes profundas con salida logística o modelos híbridos que combinen información topológica con indicadores técnicos clásicos) donde las variables TDA se empleen para mejorar la separación entre escenarios alcistas y bajistas. De este modo, el presente trabajo se interpreta como un paso preliminar: confirma la utilidad de la información topológica en un entorno de pronóstico, pero también señala que futuras investigaciones deberían centrar sus esfuerzos en marcos de modelado más cercanos a la lógica operativa del trading.

## A. Tablas y figuras adicionales

Este apéndice incluirá tablas extendidas de métricas de error de pronóstico y gráficas adicionales (por ejemplo, distribuciones de errores por activo y horizonte) una vez que los experimentos numéricos se hayan completado.

## B. Hiperparámetros y detalles de implementación

Para facilitar la reproducibilidad, este apéndice resume las decisiones clave de implementación:

- Hiperparámetros de N-BEATSX: `FREQ = "B"`, `H = 5`, `N_WINDOWS = 4`, `SEED = 42`, `MAX_STEPS = 1500`, `BATCH_SIZE = 128`, `LEARNING_RATE = 1e-3`, `SCALER_TYPE = robust`.
- Definición del objetivo: log-return winsorizados y escalados con MinMax (`logret_scaled`).
- Configuración de TDA: embedding de Takens con  $(k, s) = (4, 4)$ , complejo de Vietoris–Rips, homología en  $H_1$ , ventana deslizante  $w = 21$  días, descriptores, `tda_amplitude_h1_w21`, `tda_n_points_h1_w21`.

Activo	N	Prop. TDA mejor	Prop. sin TDA mejor	Media $\Delta e $	Mediana $\Delta e $
AAPL	5.0	0.8000	0.2000	-0.5275	-0.7125
AMZN	5.0	0.4000	0.6000	-0.0919	0.0400
BRK-B	5.0	0.6000	0.4000	-0.1434	-0.0448
GOOGL	5.0	0.8000	0.2000	-0.0315	-0.0707
LLY	5.0	0.6000	0.4000	-0.2538	-0.2176
META	5.0	0.6000	0.4000	-0.1164	-0.1488
MSFT	5.0	0.4000	0.6000	0.0829	0.1002
NVDA	5.0	0.8000	0.2000	-0.2766	-0.2643
NVO	5.0	0.4000	0.6000	0.2575	0.0854
TSM	5.0	1.0	0.0	-0.4084	-0.4341

N	Prop. TDA mejor	Prop. sin TDA mejor	Media $\Delta e $	Mediana $\Delta e $
50.0000	0.6400	0.3600	-0.1509	-0.1165

## Referencias

- [1] L. C. de Jesus, F. Fernández-Navarro, and M. Carbonero-Ruz. Enhancing financial time series forecasting through topological data analysis. *Neural Computing and Applications*, 37(9):6527–6545, Mar 2025. ISSN 1433-3058. doi: 10.1007/s00521-024-10787-x. URL <https://doi.org/10.1007/s00521-024-10787-x>.